RESEARCH REPORT

DAPO cho SlideGen: model mở tự dựng slide ít lỗi hiển thị hơn

Học tăng cường cho Qwen3.5-35B-A3B gọi công cụ XML dựng slide tiếng Việt, với reward kiểm chứng bằng ảnh thật và người chấm

SlideGen · bản 3 · 21/10/2026

Mục lục

01 · Tóm tắt một trang

02 · Bài toán và hệ thống

03 · Bước 1: dữ liệu cặp đẹp–xấu và reward thẩm mỹ

04 · Bước 2: DAPO vòng 1 và đợt chấm người đầu tiên

05 · Bước 3: lỗi "của model" hóa ra là lỗi môi trường

06 · Bước 4: hiệu chỉnh reward bằng người chấm, và các lần thử thất bại

07 · Bước 5: vòng 4, model học tóm gọn thay vì thu nhỏ chữ

08 · Bước 6: xem ảnh để vá các chỗ reward bị lừa

09 · Bước 7: tập test giữ riêng, so với model gốc và Gemini

10 · Bước 8: chấm người đợt 2 (kết quả tạm)

11 · Kết luận và việc tiếp theo

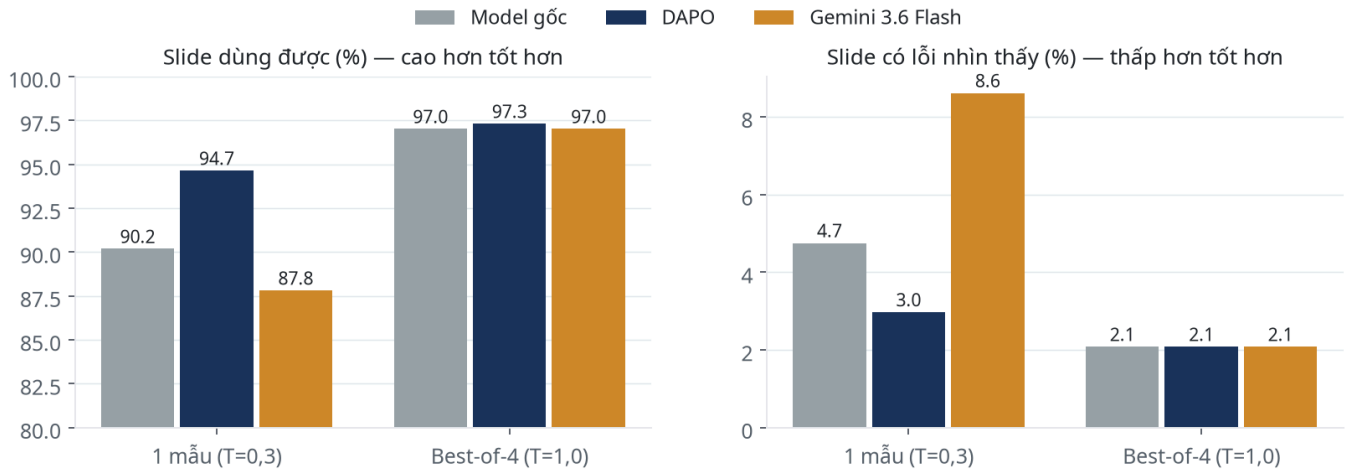
12 · Phụ lục

01 · Tóm tắt một trang

Câu hỏi. Học tăng cường (DAPO) có giúp một model mở cỡ vừa tự dựng slide tiếng Việt ít lỗi hơn không, và phần cải thiện đến từ RL hay từ việc sửa môi trường?

Hai model được so sánh

	Qwen3.5-35B-A3B + LoRA DAPO (của chúng tôi)	Gemini 3.6 Flash (đối chứng thương mại)
Loại	Mã nguồn mở, tự chạy	Đóng, gọi qua API của Google
Tổng số tham số	35 tỉ (Mixture-of-Experts, 256 expert)	Google không công bố
Tham số kích hoạt mỗi token	Khoảng 3 tỉ (8 expert + 1 expert chung)	Google không công bố
Phần được train	LoRA r=16 (QLoRA 4-bit), trên 1 GPU H100	Không train, dùng nguyên
Prompt và công cụ	Prompt vòng 4, cùng bộ công cụ XML	Cùng prompt và cùng bộ công cụ



Hình 1. Tập test giữ riêng, 337 slide: một mẫu, DAPO có nhiều slide dùng được nhất; khi được lọc best-of-4, cả ba hệ thống ngang nhau

Con số chính	Model gốc	DAPO (bản chốt)	Gemini 3.6 Flash
Slide dùng được, tập test, 1 mẫu	90,2%	**94,7%**	87,8%
Slide có lỗi nhìn thấy, tập test, 1 mẫu	4,7%	**3,0%**	8,6%
Độ phủ ý chính (keypoint), tập test	**0,811**	0,788	0,778
Slide dùng được, tập test, best-of-4	97,0%	97,3%	97,0%
Lỗi nhìn thấy, tập phát triển, 3 seed	7,6%	4,6% ± 0,7	n/a

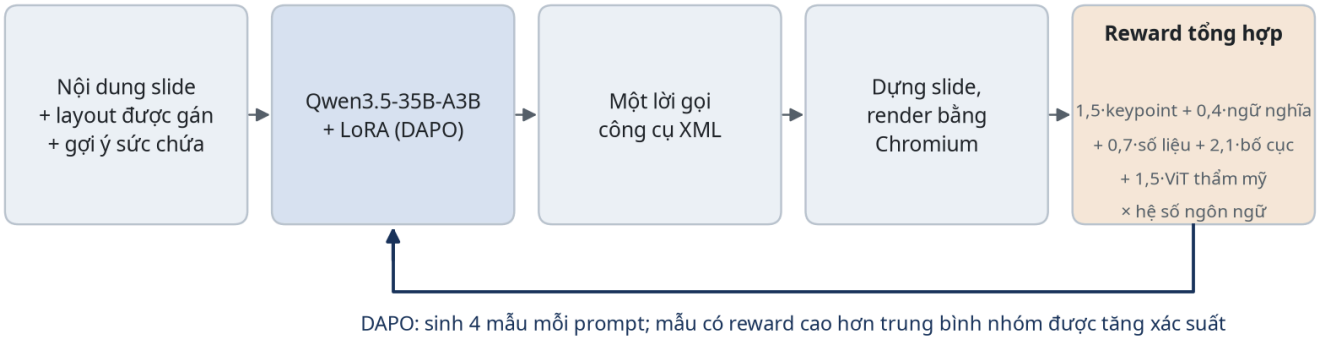
Kết luận chính

1. **DAPO giảm lỗi hiển thị, và lặp lại được qua 3 seed.** Lỗi nhìn thấy giảm gần một nửa trên tập phát triển, và từ 4,7% xuống 3,0% trên tập test chưa từng dùng.

2. **Cái giá là nội dung ngắn hơn.** Keypoint giảm khoảng 0,02, vì model học tóm gọn để vừa layout chứ không thu nhỏ chữ.
3. **RL chưa nâng trần chất lượng.** Model gốc sinh 4 mẫu rồi để reward chọn thì đạt cùng mức với DAPO (97,0% so với 97,3%). Giá trị của RL là đạt chất lượng đó chỉ với 1 mẫu, rẻ hơn 4 lần khi suy luận.
4. **Một mẫu, DAPO hơn Gemini 3.6 Flash về lỗi hiển thị**: 3,0% so với 8,6%. Lỗi của Gemini gồm gãy chữ, lộ ký hiệu Markdown và để nguyên chữ mẫu tiếng Anh.
5. **Phần lớn cải thiện đến từ việc sửa môi trường và reward.** Riêng việc sửa môi trường, chưa train, đã giảm số liệu bịa của model gốc từ 11,7% xuống 1,5%.
6. **Người chấm chưa phân biệt được DAPO với các hệ thống khác.** Theo kết quả tạm của đợt 2 (2/3 người, 651 lượt), tỉ lệ thắng tổng thể quanh 0,5 ở cả ba so sánh, và phần lớn cặp được chấm hòa.

02 · Bài toán và hệ thống

Model nhận nội dung một slide (đoạn trích tài liệu nguồn, layout được gán, gợi ý sức chứa) rồi sinh **đúng một lời gọi công cụ XML**. Công cụ dựng slide, trình duyệt render ra ảnh, và reward chấm ảnh cùng nội dung.



Hình 2. Vòng lặp train: sinh lời gọi công cụ, render, chấm bằng reward tổng hợp, cập nhật LoRA bằng DAPO

Ba khái niệm dùng suốt báo cáo

Khái niệm	Định nghĩa
Hợp lệ	Lời gọi công cụ phân tích được và công cụ chạy được
Lỗi nhìn thấy	Chữ bị cắt, chữ khó đọc trên nền, khối đè nhau, lộ ký hiệu, vượt mép slide, chữ quá nhỏ, chữ tràn khỏi nền hoặc panel
Dùng được (chỉ số chính)	Hợp lệ và không có lỗi nhìn thấy

> **Vấn đề cốt lõi.** Không ai chấm tay được hàng chục nghìn slide trong lúc train, nên reward phải tự động. Mà reward tự động thì bị model khai thác đúng ở những chỗ nó đo sai. Mọi bước trong báo cáo là một vòng lặp: đo, xem ảnh thật, tìm chỗ đo sai, sửa.

Dữ liệu

Tập	Nguồn	Quy mô	Dùng để
Train RL	44 bộ slide dựng sẵn, khoảng 18 chủ đề	370 prompt	Train DAPO
Eval lúc train	Cùng phân phối với tập train	168 slide × 4 mẫu	Early stopping
Tập phát triển	38 bài Wikipedia tiếng Việt, chủ đề mới	291 slide	Chọn checkpoint, đo seed
Tập test giữ riêng	44 bài Wikipedia khác, chủ đề không trùng hai tập trên	337 slide	Chạy đúng một lần cho bản chốt
Người chấm đợt 1	Trang so cặp mù, 3 người	1.281 lượt, 595 cặp	Kiểm chứng reward
Người chấm đợt 2	Cùng trang và giao thức, trên tập test	666 cặp (đang chấm)	Kiểm chứng kết luận cuối

Cấu hình. - Model: Qwen3.5-35B-A3B (35B tham số, khoảng 3B kích hoạt mỗi token), QLoRA NF4, LoRA r=16. - Thuật toán: DAPO qua TRL `GRPOTrainer`, 4 mẫu mỗi prompt, LR 1e-5, early stopping theo reward eval.

03 · Bước 1: dữ liệu cặp đẹp–xấu và reward thẩm mỹ

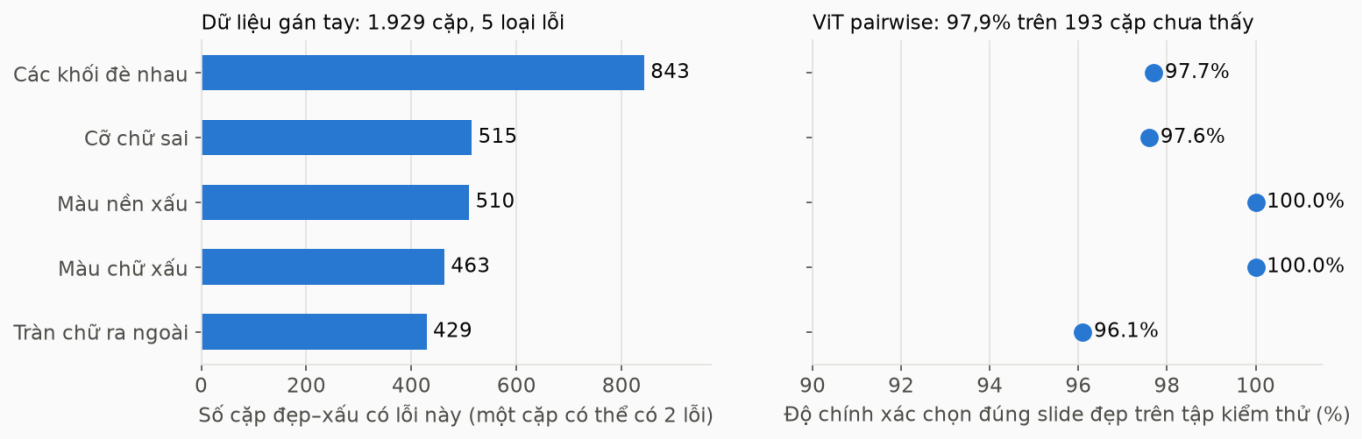
> **Kết luận: một ViT nhỏ train trên 1.929 cặp gán tay chọn đúng slide đẹp 97,9%, ngang một VLM 35B. Nhưng trên slide do model sinh, nó chỉ khớp người 60%.**

Không có bộ dữ liệu slide nào gán nhãn thẩm mỹ theo loại lỗi, còn LLM lớn thì chấm quá chậm cho RL. Vì vậy chúng tôi tự dựng 1.929 cặp, mỗi cặp gồm một slide đẹp và một bản xấu của chính nó mang một hoặc hai lỗi cụ thể.

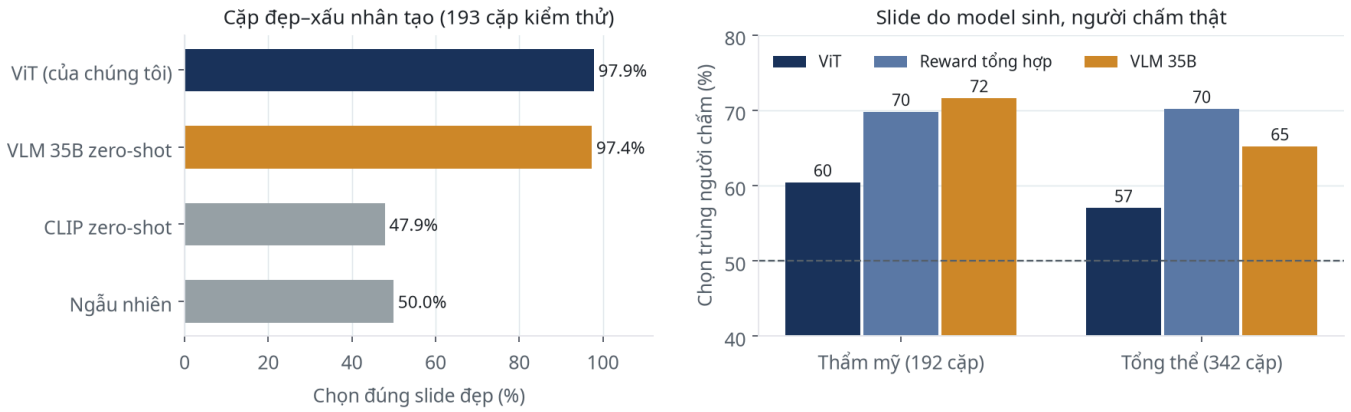


Hình 3. Mỗi cặp: cùng nội dung, bản xấu mang đúng một lỗi (viền xanh: đẹp, viền đỏ: xấu)

- 5 loại lỗi, 18 tổ hợp lỗi đơn và kép, 1.805 slide gốc, 5 người làm.
- Chia tập theo slide gốc: 1.736 cặp train và 193 cặp kiểm thử, không slide gốc nào nằm ở cả hai tập.
- ViT-Base train kiểu so cặp (loss Bradley–Terry); reward thẩm mỹ là sigmoid của điểm.



Hình 4. Số cặp theo loại lỗi và độ chính xác của ViT trên tập kiểm thử



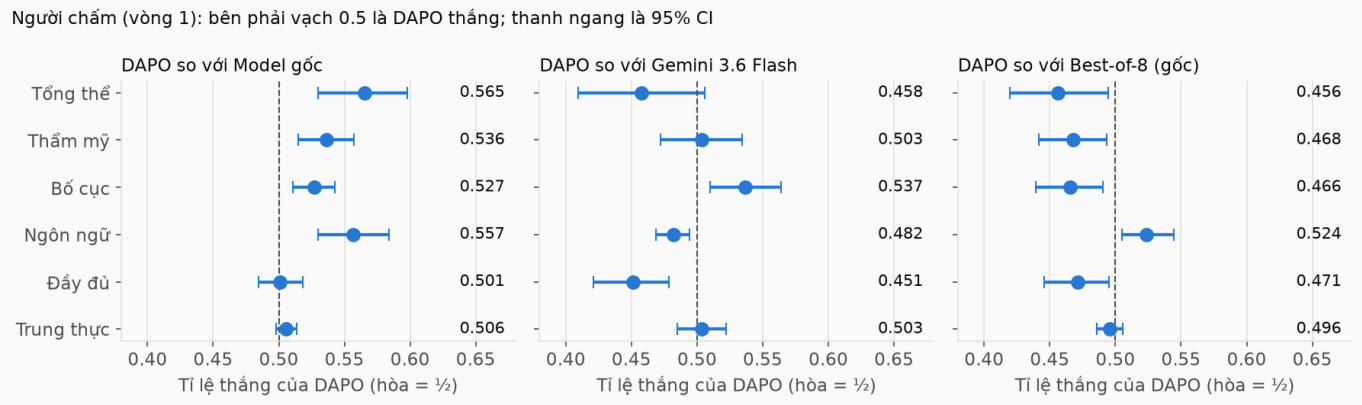
Hình 5. Trái: trên cặp nhân tạo, ViT và VLM 35B đều gần 98%, CLIP ngang ngẫu nhiên. Phải: trên slide do model sinh, mọi bộ chấm chỉ khớp người 57–72%

> **Ý rút ra.** Bộ cặp cho nhãn chắc chắn và đủ để train một reward nhỏ, nhanh. Nhưng nó không phải benchmark khó: VLM lớn không train đã đạt 97,4%. Lỗi trên slide do model sinh tinh tế hơn lỗi gán tay, nên thẩm mỹ chỉ là một thành phần của reward tổng hợp.

04 · Bước 2: DAPO vòng 1 và đợt chấm người đầu tiên

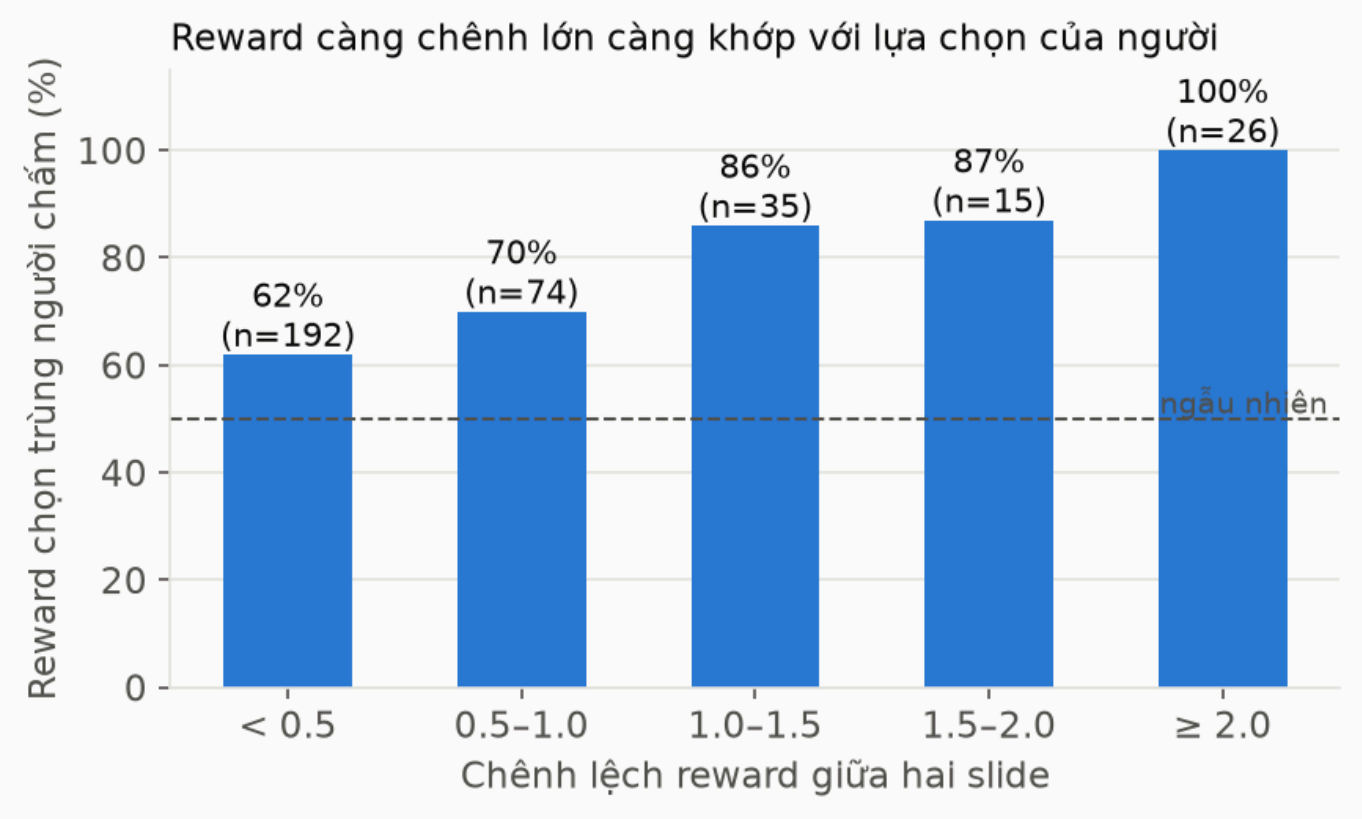
> **Kết luận: DAPO vòng 1 thắng model gốc khi người chấm, nhưng thua Gemini và thua best-of-8.**

- **Reward tổng hợp** gồm nội dung (từ vựng, ngữ nghĩa, giữ đúng số liệu), bố cục đo trong trình duyệt và ViT thẩm mỹ, nhân với hệ số đúng ngôn ngữ; lời gọi hỏng bị −2.
- **Tăng tốc train 2,7 lần** (166 → 60 giây mỗi bước) nhờ kernel flash-linear-attention và causal-conv1d, nên chạy được hơn 10 lần thử.
- **Ba người chấm so mù 595 cặp** trên tập phát triển.



Hình 6. Người chấm đợt 1: DAPO hơn model gốc ở mọi tiêu chí; thua Gemini và best-of-8 ở tiêu chí tổng thể

- **DAPO thắng model gốc 0,565** [0,530; 0,598]. Lỗi sai ngôn ngữ người đánh dấu giảm từ 11,9% xuống 3,6%.
- **DAPO thua Gemini (0,458) và best-of-8 (0,456).**
- **Reward chọn trùng người 70,6%**, và càng khớp khi hai slide chênh nhau nhiều:



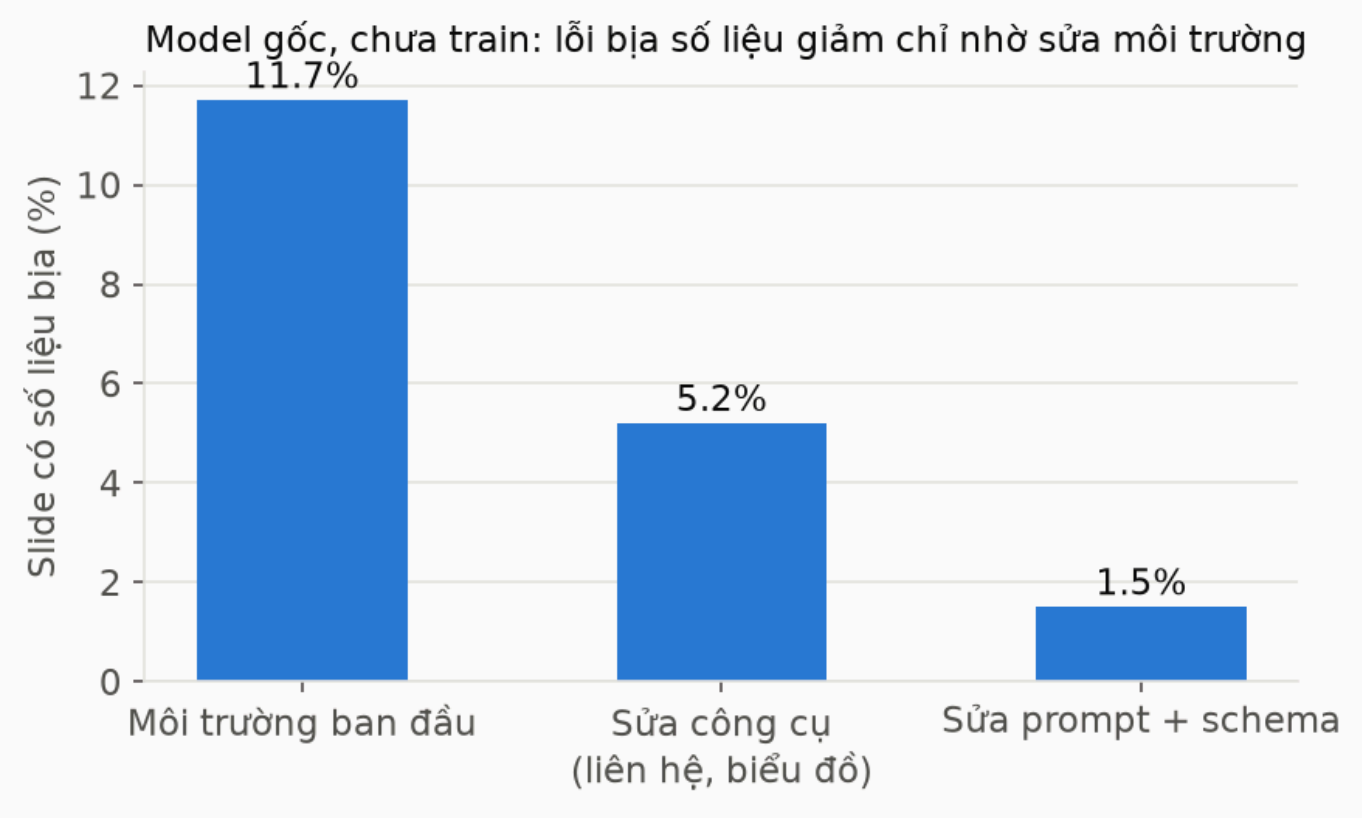
Hình 7. Reward càng chênh lệch giữa hai slide càng khớp người chấm: 62% khi chênh dưới 0,5, 100% khi chênh từ 2,0

> **Ý rút ra.** Reward có nghĩa nhưng thiếu tín hiệu. Người chấm phàn nàn nhiều nhất về chữ khó đọc trên nền và chữ tràn viền, đúng hai lỗi reward không đo.

05 · Bước 3: lỗi "của model" hóa ra là lỗi môi trường

> **Kết luận: ba lần liên tiếp, lỗi tưởng do model hóa ra do công cụ, prompt hoặc bước áp style.**

Lỗi	Nguyên nhân thật
Số liệu bịa	Công cụ slide cảm ơn tự điền số điện thoại, email mẫu khi model để trống; công cụ biểu đồ có số liệu mẫu mặc định
JSON hỏng	Một gợi ý trong prompt làm hỏng ký tự thoát JSON
Chữ khó đọc	Model chọn màu đúng, nhưng bước áp style ghi đè màu tiêu đề bằng màu dải nền. Pipeline thật có bước sửa tương phản, còn đường train và đường chấm thì bỏ qua



Hình 8. Model gốc, chưa train: số liệu bịa giảm từ 11,7% xuống 1,5% chỉ nhờ sửa công cụ và prompt



Hình 9. Mẫu slide lỗi trước khi sửa môi trường: chữ tiêu đề cùng màu với dải nền, gần như không đọc được

- **Nối thêm bước sửa tương phản:** slide có chữ khó đọc của model gốc giảm từ 17,7% xuống 0,4%.
- **Thêm hai phép đo** `low_contrast` (trên pixel nền thật) và `text_cutoff`: bộ đo bố cục bắt được 185/190 slide người đánh dấu lỗi hiển thị, trước đó chỉ 138/190.

> **Ý rút ra.** Với RL gọi công cụ, phải kiểm tra môi trường train khớp với pipeline thật trước khi tin reward. Nếu không, RL phạt model vì thứ nó không điều khiển được.

06 · Bước 4: hiệu chỉnh reward bằng người chấm, và các lần thử thất bại

> **Kết luận: dữ liệu người chấm cho trọng số lỗi bố cục và một thành phần nội dung tốt hơn. Phần lớn các thay đổi khác không qua được tập phát triển.**

- **Trọng số lỗi bố cục theo người:** lấy từ 342 cặp người chấm có kết quả rõ (820 slide). Lỗi người xác nhận 73–90% thì xóa toàn bộ điểm bố cục; tràn chiều cao khung chỉ phạt 0,25; lỗi người không bao giờ đánh dấu thì bỏ phạt.
- **Độ phủ ý chính (keypoint):** đo từng câu nguồn có được thể hiện trên slide không. Khớp người ở tiêu chí đầy đủ 70,6%, hơn trùng từ vựng (65,0%) và ngữ nghĩa cả slide (62,3%).
- **Gợi ý sức chứa đo bằng chính layout:** chạy công cụ với chữ mẫu, tìm số ký tự dài nhất không tràn cho từng trường.

Kết quả âm (giữ lại để không lặp lại):

Thử	Kết quả	Vì sao bỏ
Thêm câu "không bịa số liệu" vào prompt	Không đổi tỉ lệ bịa	Lỗi bịa chủ yếu do môi trường
Nhắc escape dấu nháy JSON trong prompt	Không đổi tỉ lệ hợp lệ	Chuyển sang sửa ở bộ phân tích
Vòng 2e: train tiếp từ 2d	Không hồi được độ phủ nội dung	Quay về LoRA mới
Tự co chữ ở layout	Lỗi nhìn thấy của model gốc 8,2% → 3,8%	Bỏ theo yêu cầu sản phẩm: cỡ chữ phải đồng nhất
Đo độ chen chữ giữa hai hộp	78/262 slide sát nhau dưới 1 px, phần lớn bình thường	Không tách được slide lỗi

> **Ý rút ra.** Thay đổi nào không qua được tập phát triển ở nhiệt độ 0,3 thì không đáng một lần train 6 giờ trên H100.

07 · Bước 5: vòng 4, model học tóm gọn thay vì thu nhỏ chữ

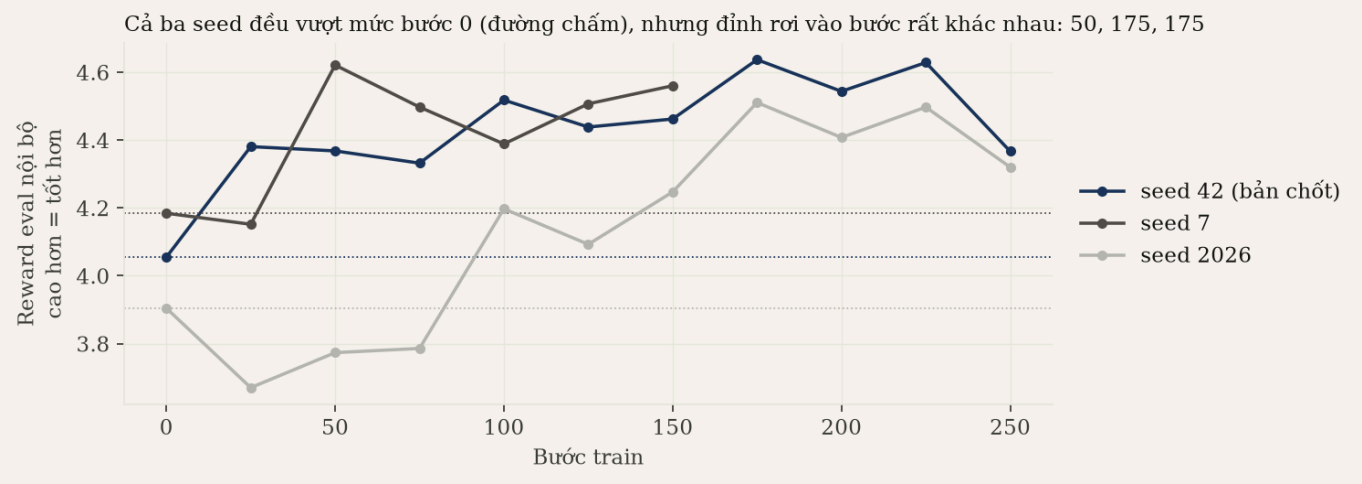
> **Kết luận: vòng 4 giảm lỗi nhìn thấy gần một nửa và lặp lại được trên 3 seed. Đổi lại, độ phủ ý chính giảm 0,02.**

- **Reward:** 1,5·keypoint + 0,4·ngữ nghĩa + 0,7·số liệu + 2,1·bố cục + 1,5·ViT, nhân hệ số ngôn ngữ. Không tự co chữ.
- **Cổng chọn bản chốt** (trên tập phát triển): hợp lệ ≥ 98%, dùng được ≥ 95%, lỗi nhìn thấy ≤ 4%, keypoint không thấp hơn gốc quá 0,03.
- **Bản chốt:** seed 42, bước 175. Hai seed lặp lại (7 và 2026) chạy trên đúng code đó.

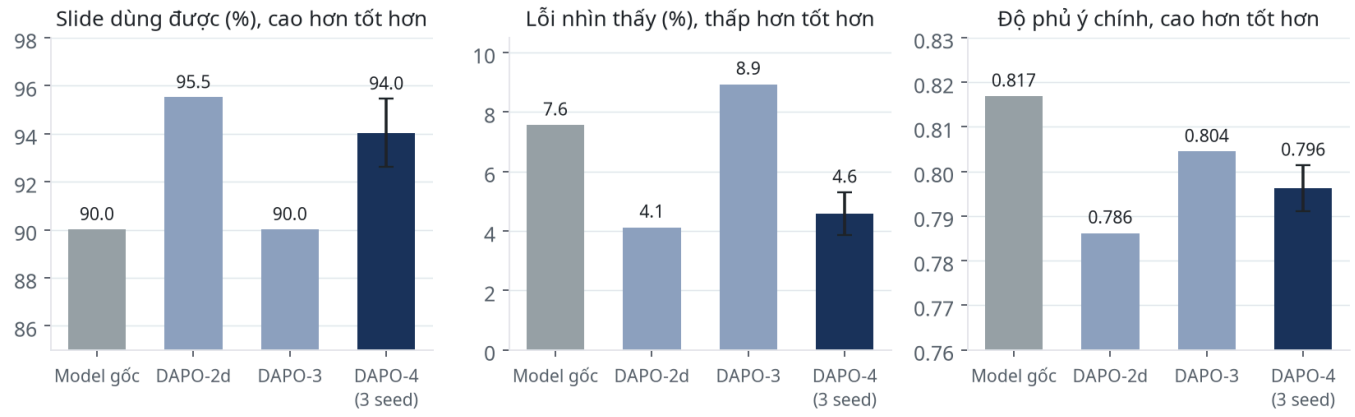
Các cấu hình so sánh trong Hình 11. Tất cả đều là cùng model Qwen3.5-35B-A3B, train DAPO trên cùng 370 prompt; chỉ reward và môi trường khác nhau. Mọi hệ thống được đánh giá lại với cùng prompt vòng 4 và cùng bộ kiểm tra.

Cấu hình	Reward nội dung	Phạt lỗi bố cục	Tự co chữ	Seed	Kết quả
Model gốc	(không train)	n/a	n/a	n/a	Mốc so sánh
DAPO-2d	Trùng từ vựng 0,5 + ngữ nghĩa 0,7	Phạt từng lỗi một phần (cắt chữ 0,40; đè khối 0,30; tràn chiều cao 0,03…)	Bật	42	Ít lỗi, nhưng viết ngắn: keypoint thấp hơn gốc 0,031
DAPO-3	Như 2d	Theo người chấm đợt 1: lỗi người thấy được mất toàn bộ điểm bố cục; tràn chiều cao mất 1/4	Bật	42	Thất bại: lỗi nhìn thấy 8,9%, cao hơn cả gốc
DAPO-4	**Keypoint 1,5** + ngữ nghĩa 0,4 (bỏ trùng từ vựng)	Như vòng 3	**Tắt** (cỡ chữ cố định)	42, 7, 2026	Qua cổng; bản chốt là seed 42

Vòng 4 cũng bắt đầu từ LoRA mới (không train tiếp vòng trước) và dùng gợi ý sức chứa v2 (đo đồng thời mọi trường, kèm số mục tối đa).



Hình 10. Ba seed đều vượt mức bước 0 nhưng đỉnh rơi vào các bước khác nhau (50, 175, 175), nên early stopping theo eval là bắt buộc



Hình 11. Tập phát triển, 291 slide, T=0,3: DAPO-4 (trung bình ± độ lệch chuẩn 3 seed) so với model gốc và các vòng trước

- **Chỉ bản chốt qua đủ cổng:** dùng được 95,2%, lỗi nhìn thấy 3,8%, keypoint 0,791 (gốc 0,817). DAPO-2d hụt sát (keypoint thấp hơn gốc 0,031); DAPO-3 hụt xa (lỗi nhìn thấy 8,9%).
- **Chữ bị cắt giảm từ 2,7% xuống 1,0% ± 0,3.** Model tóm gọn nội dung để vừa khung thay vì làm chữ nhỏ đi.
- **Ở T=0,3, slide bìa và mục lục gần như giống hệt model gốc;** khác biệt nằm ở slide nhiều chữ.

08 · Bước 6: xem ảnh để vá các chỗ reward bị lừa

> **Kết luận: năm loại lỗi có reward cao trong khi slide hỏng rõ ràng, và chỉ xem ảnh mới thấy.**

Lỗi thấy trong ảnh	Ví dụ	Kiểm tra báo nhầm
Chữ có dấu bị hỏng	*"Cùng H Fle Ph^\i^^i^^n Kh^^o^^a"*, reward 5,16	0 ca nhầm trên 17.620 slide
Chữ ngoại lai	*"Xuất khẩu ړلې Sang Tạo"*, *"trực tiếp指挥"*	Chỉ tính khi nguồn không có chữ đó
Thẻ HTML lọt	*"<Vị đậm đà"*, `<math-field>`	Mọi ca trên khoảng 15.000 slide là lỗi thật
Chữ tràn khỏi nền hoặc panel	Tiêu đề cảm ơn tràn xuống ảnh tối	Xác nhận bằng pixel hai bên mép; bản chỉ đo DOM báo nhầm khoảng một nửa
JSON hỏng vì dấu nháy lồng	*"Chiến dịch "nói không với rác thải nhựa""*	Dữ liệu đúng không đổi (51/51)

- Sửa dấu nháy JSON đưa tỉ lệ hợp lệ của model gốc từ 97,9% lên 99,3% trên tập phát triển.
- Ở T=0,3, chữ ngoại lai, chữ hỏng và thẻ lọt đều bằng 0 ở mọi hệ thống; chúng chỉ xuất hiện khi lấy mẫu ở T=1,0 lúc train (khoảng 1%).

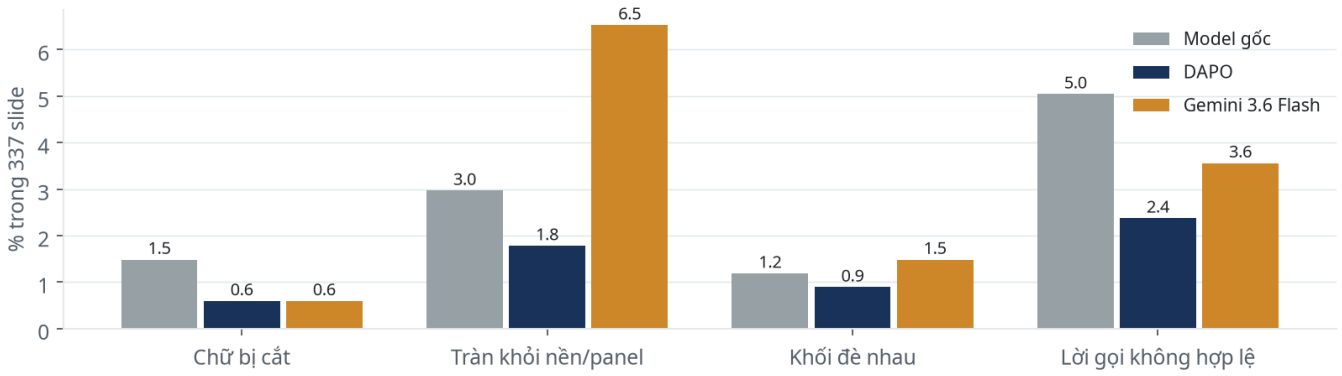
> **Ý rút ra.** Mọi bộ phát hiện phải được kiểm tra báo nhầm bằng ảnh trước khi đưa vào reward.

09 · Bước 7: tập test giữ riêng, so với model gốc và Gemini

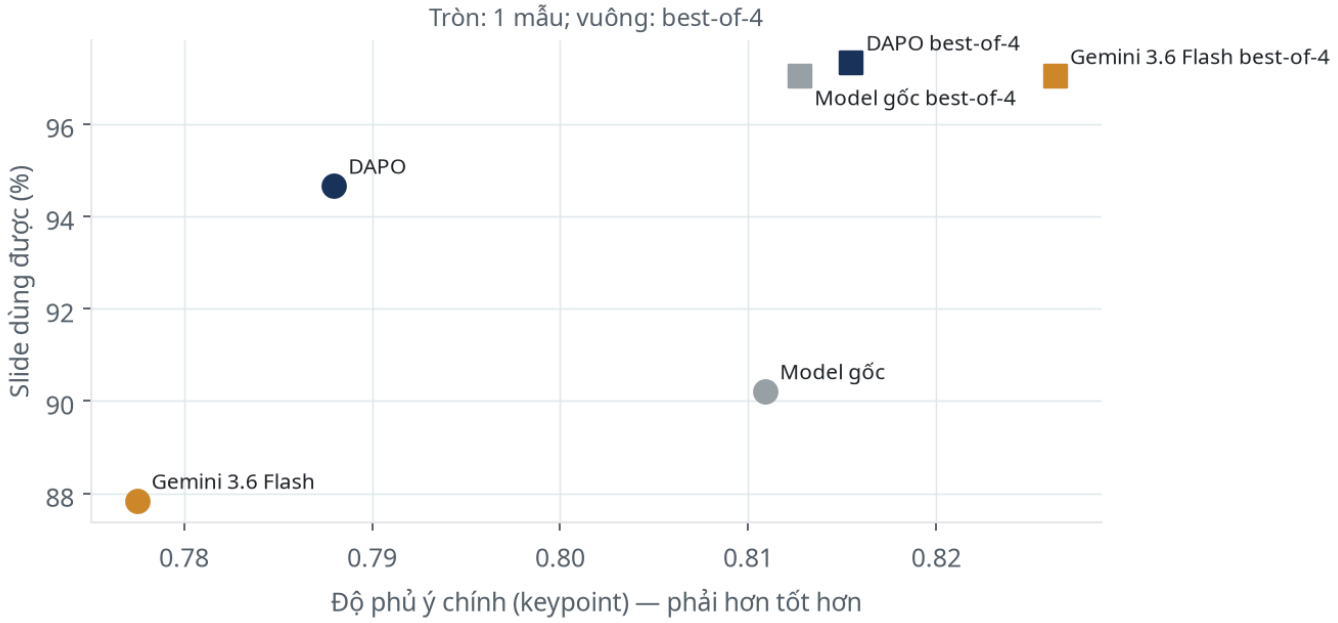
> **Kết luận: trên dữ liệu chưa từng dùng, DAPO một mẫu có ít lỗi nhất. Nhưng best-of-4 của bất kỳ hệ thống nào cũng làm được như vậy.**

Cả ba hệ thống chạy đúng một lần trên 337 slide, cùng prompt vòng 4 (có gợi ý sức chứa), cùng bộ kiểm tra, cùng môi trường render. Có hai cấu hình: 1 mẫu ở T=0,3 (cách dùng thật) và 4 mẫu ở T=1,0 rồi để reward chọn (best-of-4).

Hệ thống (337 slide)	Hợp lệ	Dùng được	Lỗi nhìn thấy	Chữ bị cắt	Tràn khung	Keypoint	Số liệu
Model gốc, 1 mẫu	95,0%	90,2%	4,7%	1,5%	3,0%	0,811	0,826
DAPO, 1 mẫu	**97,6%**	**94,7%**	**3,0%**	0,6%	1,8%	0,788	0,798
Gemini 3.6 Flash, 1 mẫu	96,4%	87,8%	8,6%	0,6%	6,5%	0,778	0,816
Model gốc, best-of-4	99,1%	97,0%	2,1%	0,6%	0,6%	0,813	0,854
DAPO, best-of-4	99,4%	97,3%	2,1%	0,6%	0,9%	0,815	0,854
Gemini, best-of-4	99,1%	97,0%	2,1%	0,9%	0,9%	0,826	0,861



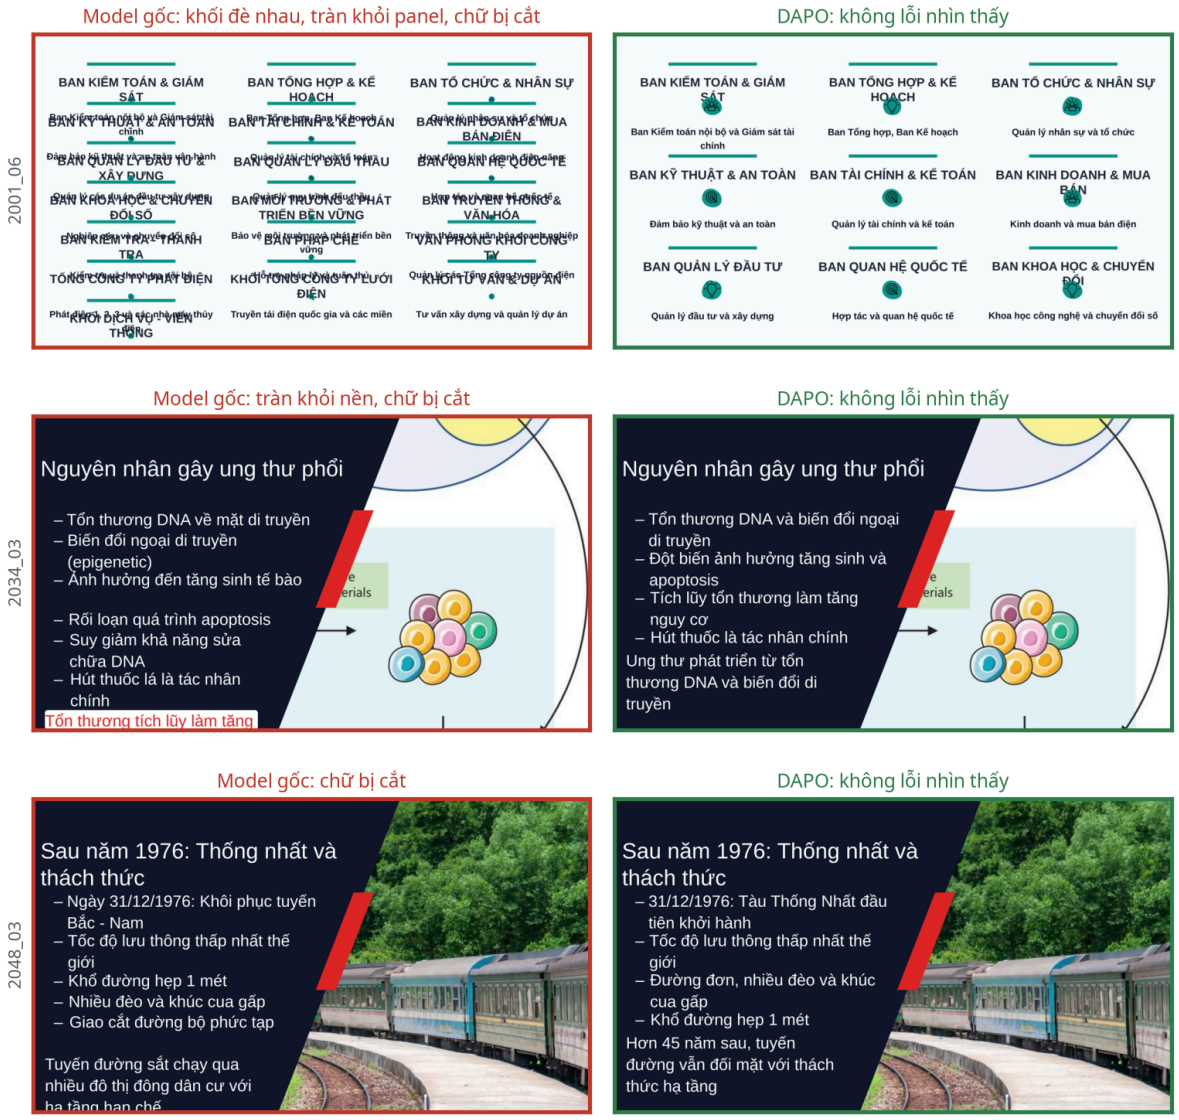
Hình 12. Loại lỗi trên tập test, 1 mẫu: DAPO giảm chữ bị cắt và lời gọi không hợp lệ; Gemini chủ yếu tràn khỏi nền/panel



Hình 13. Đánh đổi: DAPO nhiều slide dùng được hơn nhưng phủ ý chính ít hơn model gốc; best-of-4 đạt cả hai

DAPO sửa được gì so với model gốc

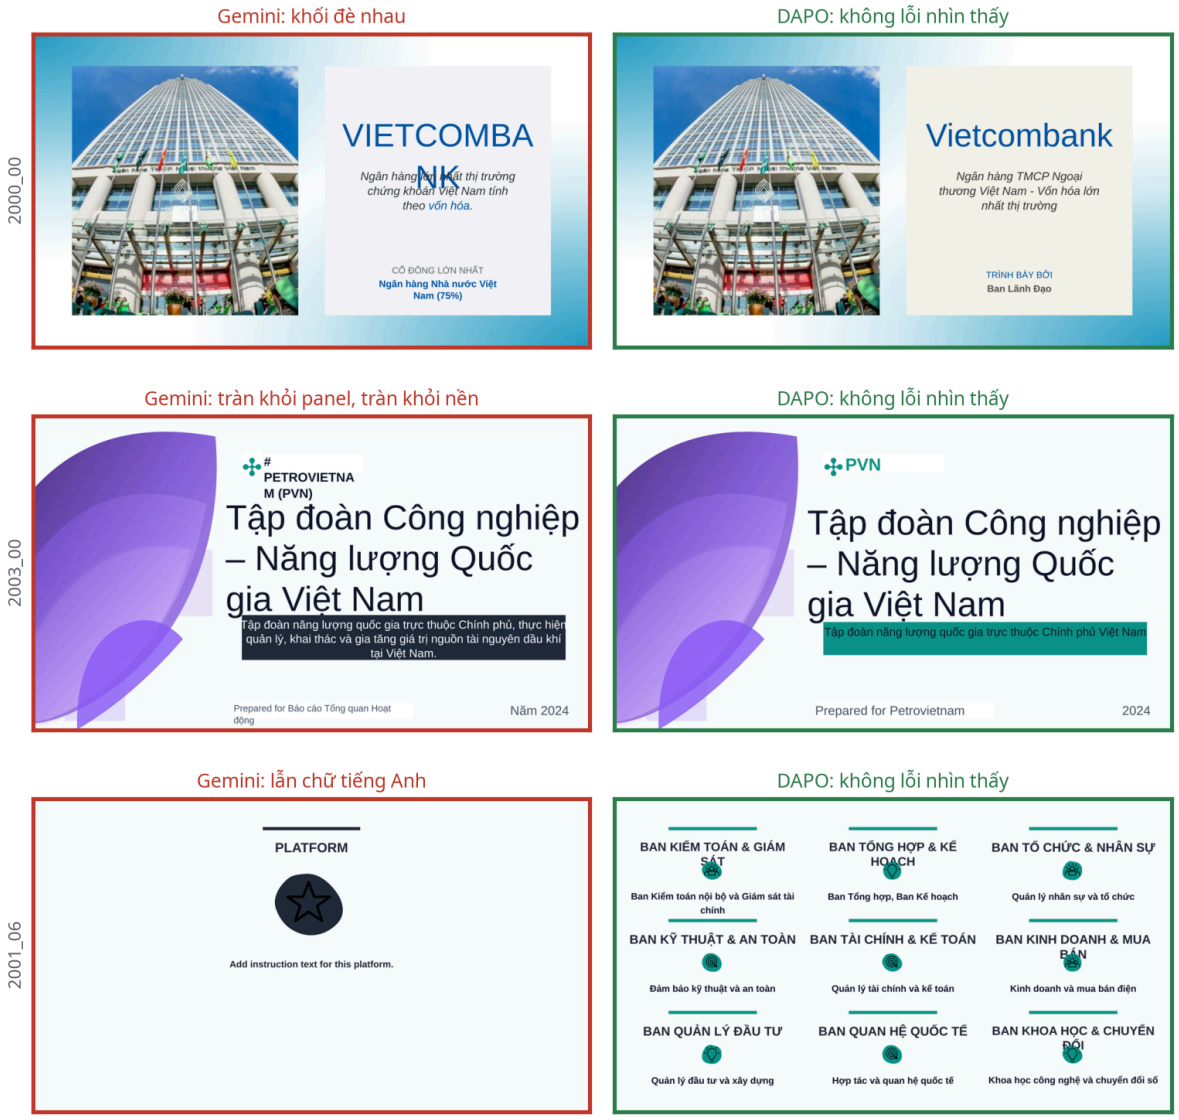
18 slide chỉ model gốc lỗi, so với 3 slide chỉ DAPO lỗi.



Hình 14. Cùng nội dung: model gốc đè chữ, tràn khung, cắt chữ; DAPO tóm gọn để vừa layout

Lỗi của Gemini 3.6 Flash

48 slide chỉ Gemini lỗi, so với 13 slide chỉ DAPO lỗi.



Hình 15. Gemini: viết hoa làm gãy chữ "VIETCOMBA/NK" đè phụ đề; để lọt ký tự Markdown "# PETROVIETNAM"; bỏ trống template, để nguyên chữ mẫu tiếng Anh

- 15 slide của Gemini bị trừ điểm ngôn ngữ vì lẫn chữ tiếng Anh, như chữ mẫu "Add instruction text for this platform" (DAPO: 3 slide, model gốc: 3 slide).
- 12 slide Gemini không hợp lệ: 8 slide vượt giới hạn số từ ghi rõ trong mô tả công cụ, 4 slide sai ràng buộc khác.
- Có gợi ý sức chứa, Gemini hết cắt chữ (từ 15,8% trên tập phát triển với prompt cũ xuống 0,6%), nhưng viết ngắn lại: keypoint 0,778, thấp hơn cả DAPO.

DAPO vẫn còn lỗi



Hình 16. Lỗi còn lại của DAPO: nhồi 15 mốc vào chú thích nhỏ (chỉ DAPO lỗi); giữ chữ mẫu tiếng Anh ở slide cảm ơn; phụ đề đè nhau ở slide bìa (model gốc cũng lỗi)

- 8 slide DAPO không hợp lệ, 7 trong số đó do vượt số mục tối đa của layout (ví dụ 13 thẻ cho layout 3 thẻ). Model gốc mắc lỗi này với tần suất tương đương.
- Lỗi slide bìa đè phụ đề (2001_00) do layout tự sinh, xuất hiện ở mọi hệ thống.

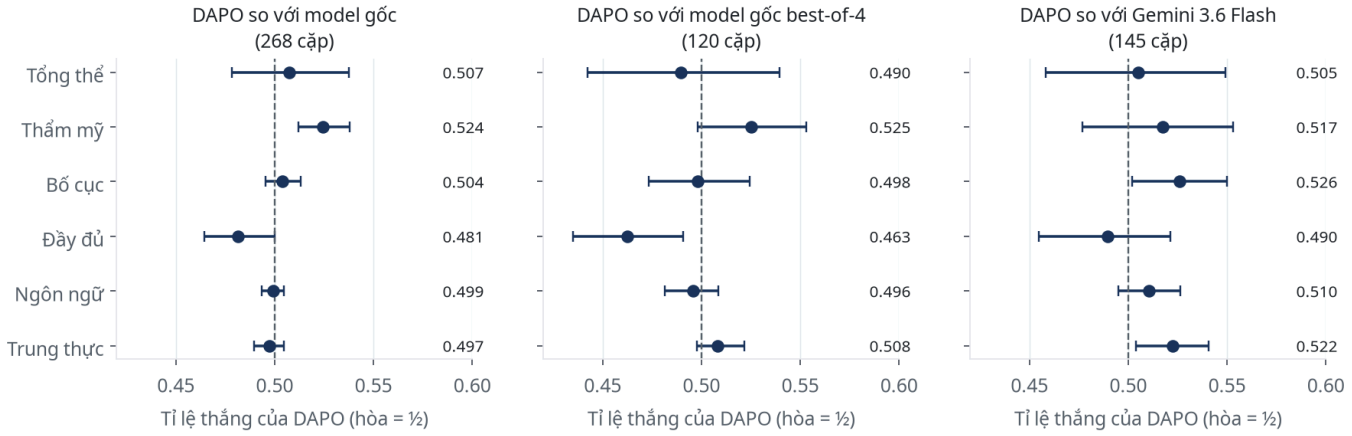
> **Ý rút ra.** RL chuyển phần chất lượng của việc lọc 4 mẫu vào một mẫu duy nhất (rẻ hơn 4 lần khi suy luận), chứ không nâng trần chất lượng.

10 · Bước 8: chấm người đợt 2 (kết quả tạm)

> **Kết luận tạm: người chấm chưa phân biệt được DAPO với model gốc, với best-of-4 hay với Gemini ở tiêu chí tổng thể. Phần lớn cặp được chấm hòa.**

Giao thức giữ y như đợt 1: chấm mù, xáo vị trí A/B, 6 tiêu chí (có lựa chọn "ngang nhau"), mỗi cặp 2 người, 15% cặp cả 3 người, 5% cặp lặp lại để kiểm tra chú ý. Slide lấy từ tập test giữ riêng, với các hệ thống ở mục 09.

Tiến độ tại thời điểm báo cáo: A1 xong 480/480, A2 197/478, A3 chưa bắt đầu. Tổng cộng 651 lượt chấm, chưa tính cặp kiểm tra chú ý.



Hình 17. Tỉ lệ thắng của DAPO theo tiêu chí, khoảng tin cậy 95% bootstrap theo bộ slide; vạch 0,5 là ngang nhau

So sánh (tiêu chí tổng thể)	Cặp	DAPO thắng	Hòa	DAPO thua	Tỉ lệ thắng [95% CI]
DAPO vs model gốc	268	31	206 (77%)	31	0,507 [0,478; 0,537]
DAPO vs model gốc best-of-4	120	19	76 (63%)	25	0,490 [0,442; 0,539]
DAPO vs Gemini 3.6 Flash	145	33	77 (53%)	35	0,505 [0,458; 0,549]

- **Thẩm mỹ là tiêu chí duy nhất DAPO hơn model gốc có ý nghĩa:** 0,524 [0,512; 0,538].
- **Độ đầy đủ DAPO hơi kém:** 0,481 so với model gốc, 0,463 so với best-of-4. Khớp với keypoint giảm 0,02 đo tự động.
- **So với Gemini, DAPO hơn về bố cục (0,526) và trung thực (0,522):** người chấm đánh dấu Gemini bịa thông tin ở 2,3% lượt, lỗi hiển thị nghiêm trọng 3,5%, sai ngôn ngữ 2,3%; DAPO lần lượt 0%, 1,4%, 0,6%.
- **Độ đồng thuận** (Krippendorff alpha) cao nhất ở bố cục (0,62), thấp ở tổng thể (0,22) và thẩm mỹ (0,18).

> **Lưu ý.** Đây là kết quả tạm: mới 2/3 người chấm, phần lớn cặp chỉ có một người, và A2 mới làm 2 cặp kiểm tra chú ý (A1 đạt 22/24). Kết luận cuối chờ A2 và A3 chấm xong.

11 · Kết luận và việc tiếp theo

DAPO giảm lỗi hiển thị một cách lặp lại được, nhưng phần lớn chất lượng đến từ việc sửa môi trường và reward. Người xem chưa thấy khác biệt.

1. Dữ liệu 1.929 cặp đẹp–xấu cho reward thẩm mỹ nhỏ, nhanh, chính xác 97,9%. Tuy vậy, tập kiểm thử của nó quá dễ để làm benchmark cho model lớn, và trên slide thật reward này chỉ khớp người 60%.
2. DAPO giảm lỗi nhìn thấy: tập phát triển 7,6% → 4,6% ± 0,7 (3 seed), tập test 4,7% → 3,0%.
3. Đánh đổi là keypoint giảm khoảng 0,02, và người chấm đợt 2 cũng thấy DAPO kém đầy đủ hơn một chút.
4. Best-of-4 của model gốc ngang DAPO best-of-4: giá trị của RL là giảm chi phí suy luận, không phải nâng trần.
5. Một mẫu, DAPO ít lỗi hơn Gemini 3.6 Flash cùng prompt (3,0% so với 8,6%), nhưng người chấm tạm thời coi hai bên ngang nhau ở tiêu chí tổng thể.
6. Ba lần lỗi môi trường và năm chỗ reward chấm sai đều chỉ lộ ra khi bóc tách từng slide và xem ảnh.

Việc tiếp theo

1. Hoàn tất chấm người đợt 2 (A2, A3), rồi chốt kết luận về sở thích người.
2. Phạt thẩm mỹ thấp bằng phép nhân thay vì cộng. Ví dụ: slide cảm ơn ghép 18 ô chữ nhỏ có ViT 0,07 nhưng reward tổng 5,04, cao hơn bản gọn 5 ô (4,94).
3. Sửa layout bìa và layout cảm ơn đang tự sinh lỗi ở mọi hệ thống: tiêu đề dài đè phụ đề, chữ mẫu tiếng Anh còn sót.
4. Thay ViT trong reward bằng bản chưng cất từ VLM, hoặc tinh chỉnh ViT trên slide do model sinh có người chấm (ViT khớp người 60%, VLM 72%).
5. Viết paper với 3 đóng góp: dữ liệu cặp + reward ViT, pipeline SlideGen + thư viện XML, train DAPO.

12 · Phụ lục

A. Bảng chi tiết tập phát triển

291 slide, T=0,3, cùng prompt vòng 4, cùng bộ kiểm tra. Số liệu sinh bằng `scripts/dev_eval_table.py` và `scripts/predicted_preference.py`.

Hệ thống	Hợp lệ	Dùng được	Lỗi nhìn thấy	Chữ bị cắt	Tràn nền	Keypoint	Số liệu	ViT	Người chọn hơn gốc (dự đoán)
Model gốc	97,6%	90,0%	7,6%	2,7%	3,1%	0,817	0,822	0,581	n/a
DAPO-2d	99,7%	95,5%	4,1%	1,4%	1,7%	0,786	0,804	0,558	0,501 [0,485; 0,519]
DAPO-3	99,0%	90,0%	8,9%	3,1%	3,4%	0,804	0,824	0,544	0,494 [0,477; 0,513]
DAPO-4 seed 42 (bản chốt)	99,0%	95,2%	3,8%	0,7%	2,7%	0,791	0,789	0,598	0,509 [0,493; 0,524]
DAPO-4 seed 7	97,6%	92,4%	5,2%	1,0%	3,4%	0,800	0,816	0,570	0,498 [0,485; 0,510]
DAPO-4 seed 2026	99,3%	94,5%	4,8%	1,4%	2,4%	0,798	0,817	0,591	0,513 [0,500; 0,529]
Gemini 3.6 Flash (prompt vòng 1, T=1,0)	96,2%	73,2%	23,0%	15,8%	n/a	0,858	0,868	n/a	n/a

Ở tập phát triển, Gemini chạy với prompt cũ chưa có gợi ý sức chứa, nên không so trực tiếp được với DAPO; so sánh công bằng nằm ở mục 09.

B. Hạn chế và cách đọc số liệu

- Tập phát triển đã dùng để chọn checkpoint và thiết kế bộ phát hiện; kết quả độc lập chỉ có ở tập test giữ riêng.
- "Xác suất người chọn (dự đoán)" là đầu ra của một hồi quy logistic fit trên 342 cặp người chấm đợt 1 (độ chính xác chéo khoảng 0,72), không phải người chấm thật.
- Reward tự động là hàm mục tiêu lúc train nên có lợi cho DAPO. Vì vậy các chỉ số hiển thị đều được kiểm bằng ảnh, và kết luận về sở thích dựa vào người chấm.
- Bảng tập test chấm lại trên máy RTX 5880, trong container có đúng bộ font của máy H100 (`scripts/score_in_h100_fonts.sh`). Slide dùng được và lỗi nhìn thấy khớp số H100; reward thấp hơn khoảng 0,02 vì 268 ảnh minh họa được tải lại đã bị nén lại, và 11 ảnh không còn tải được.
- Người chấm chọn "ngang nhau" rất nhiều (53–77% ở tiêu chí tổng thể đợt 2); độ đồng thuận ở tiêu chí đầy đủ và thẩm mỹ thấp.
- Tập train chỉ có 44 bộ slide, khoảng 18 chủ đề.

C. Thuật ngữ

- **DAPO**: biến thể của GRPO. So điểm các mẫu cùng prompt để biết mẫu nào tốt hơn, không cần model giá trị.
- **Keypoint**: tỉ lệ câu của nguồn được thể hiện trên slide, đo bằng embedding đa ngôn ngữ.
- **Best-of-N**: sinh N mẫu, reward chọn mẫu tốt nhất.
- **T=0,3 / T=1,0**: nhiệt độ lấy mẫu; 0,3 là thiết lập khi dùng thật, 1,0 là lúc train.
- **Seed**: hạt giống ngẫu nhiên quyết định thứ tự dữ liệu và việc lấy mẫu khi train.

D. Tài liệu tham khảo

- DAPO: An Open-Source LLM Reinforcement Learning System at Scale, 2025, arXiv:2503.14476.
- DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models, 2024, arXiv:2402.03300 (GRPO).
- An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale, 2021, ICLR.
- QLoRA: Efficient Finetuning of Quantized LLMs, 2023, NeurIPS.
- LoRA: Low-Rank Adaptation of Large Language Models, 2022, ICLR.
- Rank Analysis of Incomplete Block Designs: I. The Method of Paired Comparisons (Bradley, Terry), 1952, Biometrika.